RESEARCH KNOWLEDGE / CONCEPT ONE-PAGER

Reinforcement learning from human feedback (RLHF)

RLHF는 사람의 비교 평가로 보상 모델을 학습하고 언어 모델이 그 선호를 따르도록 최적화합니다.

01. 한 줄 정의 사람의 선호는 유용하지만 범위가 제한된 학습 신호입니다. 정렬 주장은 누가 어떤 프롬프트를 평가했는지 밝혀야 합니다.

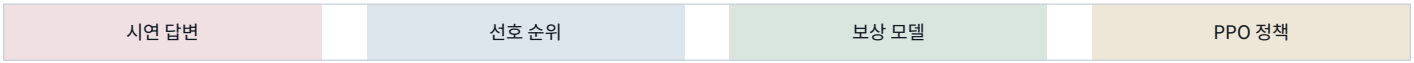

02. 입력

사람이 작성한 시연과 출력 비교를 모읍니다.

03. 학습

비교에서 보상 모델을 만들고 정책을 최적화합니다.

04. 목표

정의된 평가 집단의 선호를 모델 동작에 반영합니다.

05. 운영

평가자·기준·프롬프트 분포를 기록합니다.

06. 주의할 점

보상은 선호의 대리값이지 보편적 가치가 아닙니다.

SOURCES

https://arxiv.org/abs/2203.02155