RESEARCH KNOWLEDGE / CONCEPT ONE-PAGER

Transformer Self-attention

Transformer는 순환 상태 없이 병렬 어텐션으로 각 토큰이 다른 위치의 정보를 모으게 합니다.

01. 한 줄 정의 Self-attention은 토큰을 섞는 연산이고, Transformer는 이를 피드포워드 블록·잔차 경로·정규화·위치 정보와 결합한 전체 구조입니다.

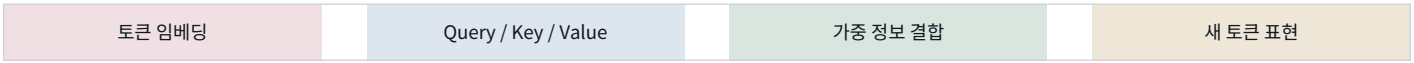

02. 무엇을 계산하나

Query-Key 유사도로 토큰 간 가중치를 만들고 Value를 섞습니다.

03. 무엇이 달라지나

순환 상태 없이 먼 토큰 관계를 병렬 계산합니다.

04. 구현 점검

길이에 따른 메모리, 마스크, 위치 정보를 확인합니다.

05. 주의할 점

어텐션 가중치를 곧바로 설명이나 인과로 해석하지 않습니다.

06. 활용

번역·언어 이해·생성 등 시퀀스 표현의 기본 연산입니다.

SOURCES

https://arxiv.org/abs/1706.03762