RESEARCH KNOWLEDGE / CONCEPT ONE-PAGER

Vision Transformer (ViT)

ViT는 이미지 패치를 토큰 시퀀스로 바꿔 표준 Transformer가 처리하게 합니다.

01. 한 줄 정의 ViT는 이미지 인식에도 Transformer 시퀀스 인터페이스를 쓸 수 있으며, 데이터 규모가 약한 시각 편향을 보완할 수 있음을 보입니다.

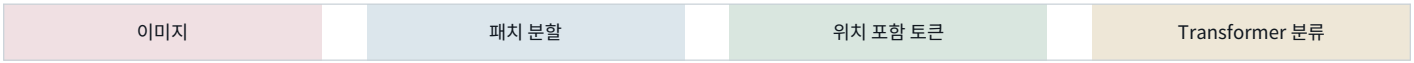

02. 입력

이미지를 같은 크기의 패치로 나눕니다.

03. 표현

각 패치를 임베딩하고 위치 정보를 더합니다.

04. 처리

토큰 시퀀스를 Transformer 인코더에 넣습니다.

05. 비용

패치 크기가 시퀀스 길이와 어텐션 비용을 바꿉니다.

06. 주의할 점

작은 데이터에서는 사전 학습 규모가 특히 중요합니다.

SOURCES

https://arxiv.org/abs/2010.11929